

# Antifraud

team 2

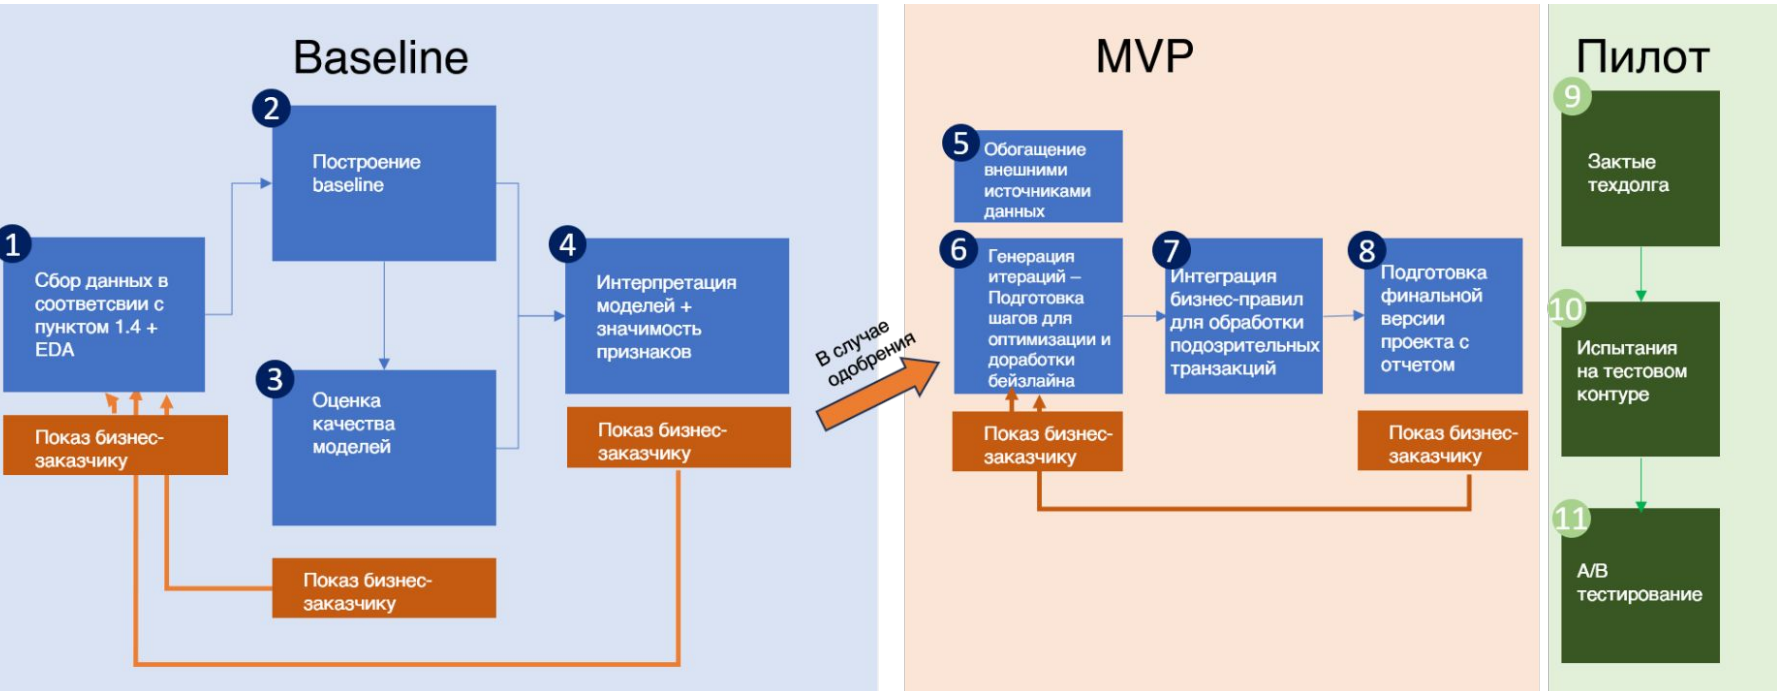
Александр Ковязин DS, СПбГУ, Sber  
Александра Оберемок, DS, Samokat.Tech  
Антон Петров DS  
Ханду Ринчинова НГУ

# Методология

## Постановка задачи

Бинарная классификация + второй шаг (выходное значение меньше определенного порога отправляем на валидацию аналитикам)

## Блок-схема решения



# Этапы решения задач

## Сбор данных

### Внутренние данные

- Переводы физических лиц
- Данные клиента
- Данные устройства, с которого переводят
- Данные по “черным спискам” из имеющейся rule-based системы
- Данные по движению средств на счетах
- История транзакции клиента

### Внешние данные

- Кредитная история
- Информация по клиенту от налоговой службы (сколько платит налогов)
- Наличие у человека ИП/ООО/Юрлиц/Банкротства физического лица
- Справка о доходах/род деятельности
- Данные службы судебных приставов + данные от коллекторов (если есть)

# Этапы решения задач

## Требования к данным + EDA

### Требования к данным

- Полнота данных, процент пропусков  $< 5\%$
- Реплицированные данные совпадают с первоисточником
- Исторические данные за 2 года
- Маппинг клиентов из разных источников

### EDA

- корреляцию, отбрасываем коррелированные данные
- анализ категориальных признаков - one-hot, label-enc, KNN
- пропущенные столбцы-строки - изучаем характер пропуска, если случайные ( $< 5\%$  удаляем, если  $>$  заполняем среднее/медиана), если пропуски, зависящие от значения признака - то флаг
- проверка наличия дубликатов
- выбросы - обрабатывает по той же логике, что и пропущенные
- смотрим на распределения внутри признаков (если по графику видим не нормальное распределение, то преобразуем, например, логарифмируем)

# Этапы решения задач

## *Бейзлайн*

**Бэйзлайн** предсказание вероятности фродовой транзакции, ориентир для сравнения качества моделей.

Простое прогнозирование эвристиками из rule-based модели либо дамми классификатор, бинарная классификация

**Таргет** - фрод или нет от аналитиков или по обращениям/жалобам

**Риски**

- сильный дисбаланс,
- могут прийти данные сильно отличающиеся от тренировочной выборки

**Метрики** - F-мера (Beta>1) macro.

Мы хотим снижать сумму штрафов, что коррелирует с технической метрикой f-metric с уклоном на recall берем коэффициент  $> 1$  и из-за дисбаланса классов берем в расчет macro.

# Pipeline обучения MVP

**Разбиение выборки** - train, OOS (shuffle) - без пересечения по клиентам, стратифицированно

**Гранулярность** - отдельная транзакция

**Частота** - ASAP, переобучение раз в сутки ночью, когда меньше всего нагрузки

**Таргет** - фрод или нет, по обращениям/жалобам/наличие штрафа/аналитики

**Метрики** - F-мера (Beta>1) macro выше бейзлайна

## Риски

- неправильное распределение таргета из-за отложенной разметки
- дороговизна внешних данных,
- разреженные данные,
- некорректные данные,
- вероятность поймать даталики,
- меняются виды мошенничества

## Feature eng

- разбиваем на элементы дату и время, адрес (если геоданные),
- склонность к определенным транзакциям,
- собираем статистики по транзакциям за предыдущие периоды,
- сегменты пользователей, которые делают переводы др др,
- частота взаимодействия между отправителем и получателем

## Алгоритм -

- кросс-валидация group stratified kfold,
- бустинг (class weighted) + логгер для калибровки,
- подбор гиперпараметров hyperopt,
- важность фичей (permutation importance, SHAP),
- отбор фичей по вкладу в метрику

## Оценка качества модели

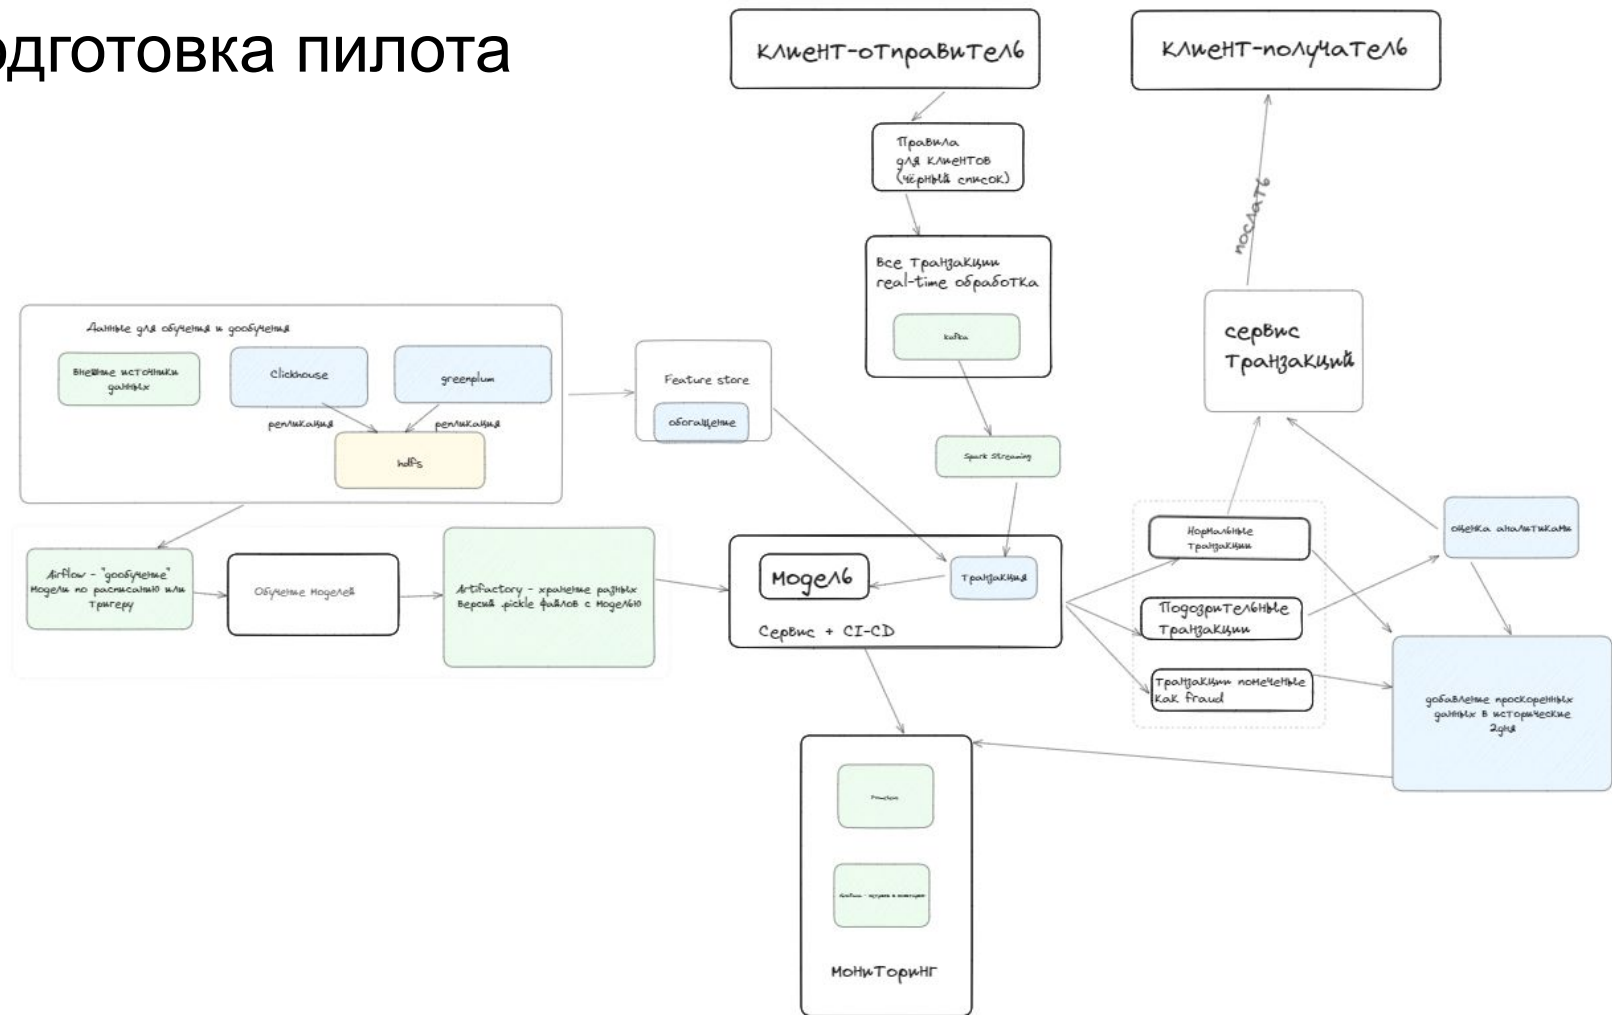
- на отличных выборках, применяем ту же предобработку и проверяем метрики,
- проверка на чувствительность к шуму,
- оценка качества на разных кластерах (по регионам, полу, возрасту)

**Демо** - интерпретация (согласование с бизнес-логикой)



Вопросы

# Подготовка пилота





# Подготовка пилота - АВ тестирование

Критерий успеха - Сокращение суммы штрафов на  $Y\%$

$H_0$  - эффекта от МЛ системы нет

$H_1$  - эффект есть, уменьшится сумма штрафов

Мощность = 80%, значимость = 0.05, MDE условно 5% ( $Y$ )

1. Размер выборки
2. Продолжительность (размер\_выборки \* 2/100\_000 транзакций) дней
3. Разбили клиентов на 2 равные группы случайно.
4. Эксперимент - на контрольной ничего не меняем, на тестовой выборке ML-решение.
5. Тест Манна-Уитни
6. Стат значимость по p-value

Вычислительные мощности:

- сервер на 200 gb, Ram 30Gb, 8 cpu для baseline расчетов
- в пилоте для 100\_000 транзакций в день, соответственно, соблюдать пропорцию на большее количество



Вопросы